

Análisis del Algoritmo YOLO basado en Redes Neuronales Convolucionales para Visión Computacional

Curso: Inteligencia Artificial – CC421A

Urbano Nieves, Ivan Marcelo
Vilca Perez, Mathias Joaquin
Santa Cruz Basilio, Jesus Diego
López Arteaga, César Omar

Universidad Nacional de Ingeniería
Faculty of Science
Escuela Profesional de Ciencias de la Computación

2026

Estructura de la Presentación

1 Parte I: Estado del Arte y Arquitectura

2 Parte II: Algoritmia y Matemáticas

- **Definición:** Campo de la Inteligencia Artificial enfocado en permitir que los sistemas computacionales extraigan información semántica a partir de imágenes y videos.
- **El Desafío de los Datos:** Una imagen a color es una matriz tridimensional de píxeles ($H \times W \times C$).
- **Limitación de Redes Tradicionales:** Las capas completamente conectadas (Fully-Connected) destruyen la topología bidimensional y provocan una explosión paramétrica inmanejable.

Clasificación de Imágenes


- Determina la presencia de una categoría macro dentro de la escena.
- Produce una única etiqueta global para toda la imagen.
- No especifica la localización ni la cantidad de instancias.

Detección de Objetos

- Identifica y localiza de forma precisa múltiples instancias en la escena.
- Genera una caja delimitadora (*Bounding Box*) para cada objeto detectado.
- Estima simultáneamente la clase y las coordenadas espaciales.

Redes Neuronales Convolucionales (CNN)

- Modelos profundamente efectivos para el procesamiento de datos bidimensionales.
- **Capas Convolucionales:** Aplican filtros locales o *kernels* que barren la imagen realizando un producto escalar elemental.
- **Extracción Jerárquica:** Las primeras capas registran bordes y texturas básicas; las capas avanzadas abstraen formas complejas y objetos.



Operación de Convolución y el Rol del Padding

- La operación de convolución discreta 2D con desplazamiento (*stride*) y relleno (*padding*) se define como:

$$(x * K)(i, j) = \sum_{m=0}^{k-1} \sum_{n=0}^{k-1} x(i \cdot s + m - p, j \cdot s + n - p) \cdot K(m, n)$$


- Hiperparámetro de Padding (P):** Adición perimetral de ceros alrededor de la entrada.
- Propósito del Padding:** Evita la pérdida drástica de información en los bordes de la imagen y permite controlar el tamaño exacto del mapa de características resultante.

- **Transformación ReLU:** Tras la convolución, se aplica la función de activación no lineal $\text{ReLU}(x) = \max(0, x)$.
- **Ventajas frente a Sigmoide y Tanh:**
 - Evita la saturación de los gradientes en el dominio positivo.
 - Resuelve el problema de desvanecimiento del gradiente (*vanishing gradient*), garantizando un aprendizaje eficiente en redes profundas.
 - Ofrece una eficiencia computacional óptima al no requerir operaciones exponenciales complejas.

Agrupamiento (Pooling) y Reducción Espacial

- **MaxPooling:** Reduce las dimensiones espaciales seleccionando el valor máximo dentro de una ventana de barrido.
- Disminuye la carga computacional y el riesgo de sobreajuste.
- Confiere al modelo cierta **invariancia a la traslación**.
- **Fórmula de Dimensión de Salida (Función Piso):**

$$W_{out} = \left\lfloor \frac{W - F + 2P}{S} \right\rfloor + 1$$




- Los algoritmos tradicionales de dos etapas (*Two-Stage Detectors*, como R-CNN) fragmentaban la localización y la clasificación de objetos.
- **Mecanismo:** Dependían de un algoritmo externo para sugerir miles de propuestas de regiones de interés en la imagen.
- **Inviabilidad en Tiempo Real:** Evaluar individualmente cada una de estas ventanas mediante una CNN pesada generaba un costo computacional masivo y velocidades de fotogramas por segundo inviables.

El Paradigma YOLO: Regresión de un Solo Vistazo

- **You Only Look Once:** Redefinió la detección al unificar las etapas de localización y clasificación en una sola red convolucional.
- **Tratamiento como Regresión:** El modelo evalúa la totalidad de la imagen en una única pasada hacia adelante (*forward pass*).
- **Comprensión Contextual:** Al procesar la imagen de manera global, asimila el contexto del fondo de la escena, reduciendo significativamente los errores por falsos positivos en comparación con los métodos locales.


- **Preprocesamiento:** Redimensionamiento de la imagen de entrada a una resolución fija de $448 \times 448 \times 3$.
- **Bloque de Extracción:** Formado por **24 capas convolucionales** profundas.
- **Estrategia de Filtros:** Combinación de kernels de 1×1 para reducir la profundidad de los canales y kernels de 3×3 para el aprendizaje espacial.
- **Capas Finales:** Dos capas completamente conectadas (FC) proyectan la información hacia el tensor final de predicción.

Diagrama de la Arquitectura de YOLO



División Espacial mediante la Cuadrícula

- El algoritmo segmenta la estructura bidimensional de la imagen en una grilla de $S \times S$ celdas.
- **Asignación de Celda Responsable:** Si el centro de un objeto cae dentro de los límites coordenados de una celda, esa celda se vuelve la única encargada de predecir el objeto.
- Cada bloque procesa de forma autónoma la predicción de múltiples cajas.



El Vector de Predicción Regresivo Y

Cada celda calcula de forma simultánea los elementos del vector de salida:

$$Y = [p_c, b_x, b_y, b_h, b_w, c_1, c_2]$$


- p_c : **Puntuación de Confianza**. Refleja la probabilidad de que la celda contenga un objeto ponderado por la precisión de la caja:

$$p_c = \text{Pr}(\text{Objeto}) \times \text{IoU}_{\text{pred}}^{\text{real}}$$

- b_x, b_y : Coordenadas del centro de la caja delimitadora, calculadas de forma **relativa a los bordes de la celda**.
- b_h, b_w : Magnitudes de altura y anchura de la caja, normalizadas respecto a las dimensiones de la imagen completa.
- c_1, c_2 : Probabilidad de pertenencia a las clases objetivo (ej. Jugador y Pelota).

Filtrado Inicial por Puntuación de Confianza

- Las puntuaciones de confianza discriminan de forma inmediata las zonas vacías de la imagen.
- Las celdas que intersectan con objetos reales muestran un valor $p_c > 0$ (destacadas en rojo).
- Las celdas correspondientes al fondo o espacio vacío (amarillas) tienden a cero ($p_c \approx 0$), descartando sus predicciones asociadas.



Ecuaciones de Parametrización Espacial

Para proyectar las salidas continuas de la red (t_x, t_y, t_w, t_h) en coordenadas reales estables sobre la imagen, se aplican las siguientes transformaciones:

$$\hat{x} = \sigma(t_x) + c_x \quad (1)$$

$$\hat{y} = \sigma(t_y) + c_y \quad (2)$$

$$\hat{w} = p_w \cdot e^{t_w} \quad (3)$$

$$\hat{h} = p_h \cdot e^{t_h} \quad (4)$$

- $\sigma(z) = \frac{1}{1+e^{-z}}$ (Función Sigmoide).
Restringe el centro $(\hat{x}, \hat{y})$ dentro de los márgenes de la celda actual.
- (c_x, c_y) representan la esquina superior izquierda de la celda evaluada.
- (p_w, p_h) corresponden a las dimensiones del *Anchor Box* base asociado.

- El entrenamiento de la regresión de cajas busca minimizar una función de pérdida $\mathcal{L}_{\text{bbox}}$ que penalice las discrepancias geométricas.
- Se optimiza directamente basándose en el remanente de la Intersección sobre Unión (IoU):

$$\mathcal{L}_{\text{IoU}} = 1 - \text{IoU}(\hat{B}, B^*)$$


- De esta manera, el modelo aprende de forma continua la función de mapeo $f_{\theta} : \mathbb{R}^d \rightarrow [0, 1]^2 \times \mathbb{R}^2$ para producir parámetros que maximicen la coincidencia física con las coordenadas reales.

Métrica Intersection over Union (IoU)

- Métrica geométrica rigurosa utilizada para evaluar la precisión del solapamiento entre la caja predicha (B_a) y la caja real (B_b):

$$\text{IoU}(B_a, B_b) = \frac{\text{Area}(B_a \cap B_b)}{\text{Area}(B_a \cup B_b)}$$

- El área de la unión se deduce analíticamente mediante la suma de áreas individuales menos su intersección.
- Sirve como filtro inicial para descartar recuadros de baja aproximación.



$$\text{Índice de Jaccard} = \frac{A \cap B}{A \cup B}$$

Algoritmo Non-Maximum Suppression (NMS)

- Debido a la superposición celular, un mismo objeto suele activar múltiples cajas válidas a la vez. El algoritmo NMS filtra de forma recursiva estas redundancias:

Algoritmo de Supresión No Máxima (NMS)

- 1 Ordenar descendientemente todas las cajas candidatas según su puntaje $S(i)$.
- 2 Seleccionar la caja de máxima confianza B_m , removerla del conjunto y consolidarla en el subconjunto definitivo $\mathcal{R}$.
- 3 Evaluar el resto de las cajas y eliminar aquellas cuyo IoU con respecto a la caja ganadora B_m supere el umbral de tolerancia τ :

$$\text{IoU}(B_m, B_j) > \tau$$

- 4 Repetir el procedimiento hasta procesar la totalidad de las propuestas.

- **Cálculo de Dimensiones por Caja (R):** Cada caja delimitadora codifica geometría (4), confianza (1) y clases (K), representando una dimensión vectorial de:

$$R = 4 + 1 + K$$

- **Volumen por Celda (Q):** Con un número B de cajas alternativas estimadas por celda, el tamaño del bloque es:

$$Q = B \times R$$

- **Criterio de Inferencia:** Una detección de clase i es finalmente aceptada y desplegada en tiempo real si cumple el umbral mínimo condicional establecido:

$$\Pr(\text{Objeto}) \times \Pr(\text{Clase}_i \mid \text{Objeto}) > \tau$$

Tareas principales de reentrenamiento

- **Detector de Persona (César)** Modelo afinado sobre un dataset específico enfocado en una sola persona.
- **Detector de Vehículos:** Modelo afinado sobre imágenes de tránsito urbano para la detección de automóviles.

Métricas utilizadas

- **Precisión (Precision):** Proporción de verdaderos positivos sobre el total de predicciones positivas. Indica la exactitud en la detección (evitar falsos positivos).
- **Sensibilidad (Recall)** Proporción de verdaderos positivos sobre el total de objetos reales en la escena. Indica la capacidad del modelo para encontrar todos los objetos (evitar falsos negativos).
- **mAP@50:** Media de la Precisión Promedio con un umbral de intersección sobre unión (IoU) de 0.5.
- **mAP@50-95** Media de la Precisión Promedio evaluada en múltiples umbrales de IoU desde 0.5 hasta 0.95 (con incrementos de 0.05). Mide la calidad de la delimitación espacial (bounding box localization)

Tareas principales de reentrenamiento

Cuadro: Métricas finales del reentrenamiento de YOLOv11.

Modelo / Dataset	Precision	Recall	mAP@50	mAP@50-95
Detección de Persona (César)	98.95 %	100.00 %	99.50 %	81.01 %
Detección de Vehículos	100.00 %	98.56 %	99.49 %	60.71 %

- El reentrenamiento (fine-tuning) de YOLOv11 en datasets de escala reducida demuestra que los modelos preentrenados en grandes bases de datos (como MS COCO) poseen una alta transferencia de aprendizaje (transfer learning), logrando converger rápidamente (en solo 10 épocas) con métricas superiores al 98
- La arquitectura YOLOv11n (nano) demuestra ser altamente eficiente y adecuada para su ejecución local en arquitecturas de hardware estándar (como CPUs de escritorio), ofreciendo tiempos de inferencia viables (alrededor de 110-180 ms por imagen) sin requerir GPUs de gama alta para tareas de despliegue básico.
- Para mitigar los errores ante oclusiones y objetos de dimensiones reducidas, es indispensable robustecer el dataset mediante técnicas avanzadas de aumentación de datos (como mosaicos y mezclas de escala) e incorporar imágenes con mayor variedad de iluminación y densidad urbana en trabajos futuros.